

Approximative Darstellung reeller Zahlen

Max Recker

max.recker@uni-bielefeld.de

5.5.2026

1 4.1 b-adische Darstellung reeller Zahlen

Satz 1. Sei $b \in \mathbb{N}$ mit $b \geq 2$ und $x \in \mathbb{R} \setminus \{0\}$. Dann existieren eindeutig bestimmte Zahlen

$$E \in \mathbb{Z}, \quad \sigma \in \{-1, 1\}, \quad z_i \in \{0, 1, \dots, b-1\}$$

für alle $i \in \mathbb{N} \cup \{0\}$, so dass

$$\{i \in \mathbb{N} \mid z_i \neq b-1\} \text{ ist unendlich,} \quad z_0 \neq 0,$$

und

$$x = \sigma b^E \left(\sum_{i=0}^{\infty} z_i b^{-i} \right).$$

Diese Darstellung heißt die normalisierte b-adische Darstellung von x .

Beweis der Aussage

Sei $x \in \mathbb{R} \setminus \{0\}$. Das Vorzeichen ist eindeutig durch

$$\sigma = \begin{cases} -1, & x < 0, \\ 1, & x > 0 \end{cases}$$

festgelegt.

Normierung der Mantisse

Für Ziffern $z_i \in \{0, \dots, b-1\}$ mit $z_0 \neq 0$ gilt $z_0 \geq 1$. Daher folgt

$$\sum_{i=0}^{\infty} z_i b^{-i} = z_0 + \sum_{i=1}^{\infty} z_i b^{-i} \geq z_0 \geq 1.$$

Andererseits gilt wegen $z_i \leq b-1$

$$\sum_{i=0}^{\infty} z_i b^{-i} \leq \sum_{i=0}^{\infty} (b-1) b^{-i} = (b-1) \frac{1}{1 - \frac{1}{b}} = b.$$

Da zusätzlich unendlich viele Indizes $i \in \mathbb{N}$ mit $z_i \neq b - 1$ existieren, kann der Wert b nicht erreicht werden. Also gilt

$$1 \leq \sum_{i=0}^{\infty} z_i b^{-i} < b.$$

Bestimmung des Exponenten und Rekursion für die Ziffern

Aus der Normierungsbedingung

$$1 \leq a_0 < b, \quad a_0 = b^{-E}|x|$$

folgt

$$b^E \leq |x| < b^{E+1}.$$

Damit ist

$$E = \lfloor \log_b |x| \rfloor$$

eindeutig festgelegt. Nun setzen wir

$$a_0 := b^{-E}|x|$$

und definieren rekursiv

$$z_i := \lfloor a_i \rfloor, \quad a_{i+1} := b(a_i - z_i).$$

Da $1 \leq a_0 < b$, gilt $z_0 \neq 0$ und $z_0 \in \{1, \dots, b-1\}$. Außerdem folgt aus $0 \leq a_i - z_i < 1$, dass

$$0 \leq a_{i+1} < b.$$

Also gilt für alle $i \geq 1$:

$$z_i = \lfloor a_i \rfloor \in \{0, \dots, b-1\}.$$

Darstellung von a_0 durch Partialsummen und Restglied

Wir behaupten:

$$a_0 = \sum_{i=0}^n z_i b^{-i} + a_{n+1} b^{-n-1} \quad (n \in \mathbb{N} \cup \{0\}).$$

Beweis durch vollständige Induktion

Für $n = 0$ gilt wegen $a_1 = b(a_0 - z_0)$:

$$z_0 + \frac{a_1}{b} = z_0 + (a_0 - z_0) = a_0.$$

Damit ist der Induktionsanfang gezeigt.

Sei nun $n \in \mathbb{N}$ und die Aussage gelte für $n - 1$, also

$$a_0 = \sum_{i=0}^{n-1} z_i b^{-i} + a_n b^{-n}.$$

Aus $a_{n+1} = b(a_n - z_n)$ folgt

$$a_n = z_n + \frac{a_{n+1}}{b}.$$

Einsetzen liefert

$$a_0 = \sum_{i=0}^{n-1} z_i b^{-i} + \left(z_n + \frac{a_{n+1}}{b} \right) b^{-n} = \sum_{i=0}^n z_i b^{-i} + a_{n+1} b^{-n-1}.$$

Damit ist der Induktionsschritt gezeigt.

Übergang zur unendlichen Darstellung

Aus

$$a_0 = \sum_{i=0}^n z_i b^{-i} + a_{n+1} b^{-n-1}$$

folgt durch Grenzübergang $n \rightarrow \infty$, dass

$$a_0 = \sum_{i=0}^{\infty} z_i b^{-i},$$

denn wegen $0 \leq a_{n+1} < b$ gilt

$$0 \leq a_{n+1} b^{-n-1} < b^{-n} \rightarrow 0.$$

Eindeutigkeit der Darstellung

Die Bedingung, dass unendlich viele Indizes i mit $z_i \neq b-1$ existieren, verhindert Darstellungen wie

$$1,0000 \dots = 0,9999 \dots$$

Wäre die Menge

$$\{ i \in \mathbb{N} \mid z_i \neq b-1 \}$$

endlich, dann gäbe es ein n_0 , so dass $z_i = b-1$ für alle $i > n_0$. Dann wäre

$$\sum_{i=n_0+1}^{\infty} (b-1) b^{-i} = b^{-n_0}.$$

Man könnte also die Ziffer an Stelle n_0 um 1 erhöhen und danach nur noch Nullen schreiben, sofern $z_{n_0} < b-1$. Genau solche Doppeldarstellungen werden durch die Zusatzbedingung ausgeschlossen.

Angenommen, es gäbe zwei verschiedene normalisierte Darstellungen

$$\sum_{i=0}^{\infty} y_i b^{-i} = \sum_{i=0}^{\infty} z_i b^{-i}.$$

Sei

$$n := \min\{i \in \mathbb{N}_0 \mid y_i \neq z_i\}.$$

Ohne Einschränkung sei $y_n < z_n$. Dann gilt $y_n \leq z_n - 1$. Für den Rest der linken Darstellung erhält man

$$\sum_{i=n+1}^{\infty} y_i b^{-i} \leq \sum_{i=n+1}^{\infty} (b-1) b^{-i} = b^{-n}.$$

Damit folgt

$$\sum_{i=0}^{\infty} y_i b^{-i} \leq \sum_{i=0}^{n-1} z_i b^{-i} + (z_n - 1) b^{-n} + b^{-n} = \sum_{i=0}^{n-1} z_i b^{-i} + z_n b^{-n}.$$

Da die rechte Darstellung wegen der Ziffern nach n mindestens diesen Wert besitzt, gilt zunächst

$$\sum_{i=0}^{\infty} y_i b^{-i} \leq \sum_{i=0}^{\infty} z_i b^{-i}.$$

Gleichheit könnte nur eintreten, wenn in der linken Darstellung ab Stelle $n+1$ nur noch Ziffern $b-1$ auftreten. Dies ist durch die Normalisierungsbedingung ausgeschlossen. Also gilt sogar

$$\sum_{i=0}^{\infty} y_i b^{-i} < \sum_{i=0}^{\infty} z_i b^{-i},$$

ein Widerspruch. Damit ist die Darstellung eindeutig.

2 4.2 Maschinenzahlen

Definition 2. Seien $b, m \in \mathbb{N}$ mit $b \geq 2$. Eine b -adische, m -stellige, normalisierte Gleitkommazahl hat die Form

$$x = \sigma b^E \left(\sum_{i=0}^{m-1} z_i b^{-i} \right),$$

wobei $\sigma \in \{-1, 1\}$, $E \in \mathbb{Z}$, $z_0 \neq 0$ und $z_i \in \{0, \dots, b-1\}$ gilt.

Der Grundgedanke lautet: Ein Rechner kann nur endlich viele Stellen speichern. Deshalb arbeitet man mit endlich vielen Mantissenziffern.

Maschinenzahlbereich

Für die Darstellung von Zahlen im Rechner müssen Werte für $b, m, E_{\min}, E_{\max}$ gewählt werden. Diese Wahl bestimmt den Maschinenzahlbereich

$$F(b, m, E_{\min}, E_{\max}).$$

Dieser ist definiert durch

$$F(b, m, E_{\min}, E_{\max}) = \{0\} \cup \left\{ \sigma b^E \left(\sum_{i=0}^{m-1} z_i b^{-i} \right) \left| \begin{array}{l} \sigma \in \{-1, 1\}, \\ E_{\min} \leq E \leq E_{\max}, \\ z_0 \neq 0, \\ z_i \in \{0, \dots, b-1\} \end{array} \right. \right\}.$$

Die Elemente eines solchen endlichen Maschinenzahlbereichs heißen *Maschinenzahlen*.

Der IEEE-754-Standard

Im Jahr 1985 wurde der IEEE-754-Standard veröffentlicht. Die normalisierten endlichen **double**-Zahlen entsprechen im Wesentlichen

$$F_{\text{double}} := F(2, 53, -1022, 1023).$$

Speicherbedarf von double

Zur Darstellung einer normalisierten **double**-Zahl genügen 64 Bit: 1 Bit für das Vorzeichen, 11 Bits für den Exponenten und 52 gespeicherte Bits für die Mantisse.

Das sogenannte Hidden Bit

Bei normalisierten Binärzahlen gilt stets $z_0 = 1$. Dieses erste Mantissenbit muss daher nicht explizit gespeichert werden.

Bitaufbau einer normalisierten double-Zahl

Die 64 Bits zerfallen in

$$\boxed{1 \text{ Bit}} \quad \boxed{11 \text{ Bits}} \quad \boxed{52 \text{ Bits}}$$

für Vorzeichen, Exponent und Mantisse.

Dabei codiert das Vorzeichenbit den Wert $\frac{1-\sigma}{2}$, die Exponentbits codieren den verschobenen Exponenten $E + 1023$, und die Mantissenbits speichern die Ziffern $z_1, z_2, \dots, z_{52}$.

Reservierte Exponentenwerte werden für 0, subnormale Zahlen, $+\infty$, $-\infty$ und NaN verwendet.

Der Darstellungsbereich $\text{range}(F)$

Wir bezeichnen mit

$$\text{range}(F) := [\min\{f \in F \mid f > 0\}, \max F]$$

das kleinste Intervall, in dem alle positiven Maschinenzahlen liegen.

3 4.3 Rundungen

Definition 3. Sei

$$F = F(b, m, E_{\min}, E_{\max})$$

ein Maschinenzahlbereich. Eine Rundung auf F ist eine Abbildung

$$\text{rd} : \mathbb{R} \rightarrow F,$$

die jeder Zahl x eine nächstgelegene Maschinenzahl zuordnet, also

$$|x - \text{rd}(x)| = \min_{a \in F} |x - a|.$$

Mehrdeutige Rundungen

Eine Rundung muss nicht eindeutig sein. Liegt eine Zahl genau in der Mitte zwischen zwei Maschinenzahlen, so haben beide denselben Abstand zu dieser Zahl.

Beispiel

Im Maschinenzahlbereich $F(10, 2, 0, 2)$ liegt 12,5 genau zwischen 12 und 13. Daher könnte man sowohl auf 12 als auch auf 13 runden.

IEEE-754-Regel: Runden zur geraden Zahl

Der IEEE-754-Standard verwendet im Zweifelsfall die Regel, dass so gerundet wird, dass die letzte gespeicherte Stelle gerade ist.

Absolute und relative Fehler

Definition 4. Seien $x, \tilde{x} \in \mathbb{R}$, wobei $\tilde{x}$ eine Näherung von x sei. Dann heißt

$$|x - \tilde{x}|$$

der absolute Fehler. Falls $x \neq 0$, heißt

$$\left| \frac{x - \tilde{x}}{x} \right|$$

der relative Fehler.

Definition der Maschinengenauigkeit

Definition 5. Sei F ein Maschinenzahlbereich. Die Maschinengenauigkeit von F wird definiert durch

$$\varepsilon(F) := \sup \left\{ \left| \frac{x - \text{rd}(x)}{x} \right| \mid x \in \mathbb{R}, |x| \in \text{range}(F) \right\}.$$

Dabei bezeichnet rd eine Rundung auf den Maschinenzahlbereich F .

Satz zur Maschinengenauigkeit

Satz 6. Für jeden Maschinenzahlbereich

$$F = F(b, m, E_{\min}, E_{\max}) \quad (E_{\min} < E_{\max})$$

gilt

$$\varepsilon(F) = \frac{1}{1 + 2b^{m-1}}.$$

Interpretation

Größeres m bedeutet kleinere Rundungsfehler und damit genaueres Rechnen. Die Basis b beeinflusst den Abstand benachbarter Maschinenzahlen.

Beweisidee

Der größte relative Rundungsfehler entsteht genau zwischen zwei benachbarten Maschinenzahlen bei der kleinsten Größenordnung $b^{E_{\min}}$. Dort beträgt der Abstand benachbarter Zahlen

$$b^{E_{\min}} b^{-m+1},$$

also ist der maximale absolute Fehler

$$\frac{1}{2} b^{E_{\min}} b^{-m+1}.$$

Für

$$x = b^{E_{\min}} \left(1 + \frac{1}{2} b^{-m+1} \right)$$

liegt x genau in der Mitte zwischen

$$b^{E_{\min}} \quad \text{und} \quad b^{E_{\min}} (1 + b^{-m+1}).$$

Damit darf man etwa $\text{rd}(x) = b^{E_{\min}}$ wählen und erhält

$$\left| \frac{x - \text{rd}(x)}{x} \right| = \frac{\frac{1}{2} b^{-m+1}}{1 + \frac{1}{2} b^{-m+1}} = \frac{1}{1 + 2b^{m-1}}.$$

Folglich gilt

$$\varepsilon(F) \geq \frac{1}{1 + 2b^{m-1}}.$$

Für die umgekehrte Abschätzung sei $x \in \text{range}(F) \setminus F$. Zwischen den beiden benachbarten Maschinenzahlen

$$x' = b^E \sum_{i=0}^{m-1} z_i b^{-i}, \quad x'' = x' + b^E b^{-m+1}$$

liegt x . Daher gilt

$$|x - \text{rd}(x)| \leq \frac{1}{2} b^E b^{-m+1}.$$

Da wegen der Normierung $x \geq b^E$ gilt, folgt

$$\left| \frac{x - \text{rd}(x)}{x} \right| \leq \frac{\frac{1}{2} b^E b^{-m+1}}{b^E + \frac{1}{2} b^E b^{-m+1}} = \frac{1}{1 + 2b^{m-1}}.$$

Also gilt auch

$$\varepsilon(F) \leq \frac{1}{1 + 2b^{m-1}}.$$

Zusammen ergibt sich

$$\varepsilon(F) = \frac{1}{1 + 2b^{m-1}}.$$

Definition 7. Sei F ein Maschinenzahlbereich und $s \in \mathbb{N}$. Eine Maschinenzahl $f \in F$ besitzt mindestens s signifikante Stellen in der b -adischen Gleitkomma-darstellung, falls $f \neq 0$ gilt und für jede Rundung rd sowie jede Zahl $x \in \mathbb{R}$ mit

$$\text{rd}(x) = f$$

die Abschätzung

$$|x - f| \leq \frac{1}{2} b^{\lfloor \log_b |f| \rfloor + 1 - s}$$

erfüllt ist.

4 4.4 Maschinenzahlarithmetik

Sei $\circ$ eine der vier Operationen

$$\{+, -, \cdot, /\}.$$

Für $x, y \in F$ gilt im Allgemeinen nicht

$$x \circ y \in F.$$

Das exakte mathematische Ergebnis ist also oft keine darstellbare Maschinenzahl.

Beispiel

$$10^{300} \cdot 10^{300} = 10^{600}$$

kann außerhalb des Wertebereichs liegen.

Ersatzoperation auf dem Rechner

Darum verwendet ein Computer nicht die exakte Operation, sondern rechnet mit Rundung zurück in den Maschinenzahlbereich. Wir schreiben dafür:

$$x \odot y \in F.$$

Annahme 4.12

Für eine Rundung rd zu F und alle $x, y \in F$ gelte

$$x \odot y = \text{rd}(x \circ y).$$

Korrektes Runden ist daher wesentlich komplizierter.

Beispiel 4.13

Sei $F = F(10, 2, -5, 5)$ sowie

$$x = 4,5 \cdot 10^1 = 45, \quad y = 1,1 \cdot 10^0 = 1,1.$$

Es werde jeweils auf zwei Mantissenstellen gerundet.

$$\begin{aligned} x \oplus y &= \text{rd}(x + y) = \text{rd}(46,1) = 4,6 \cdot 10^1, \\ x \ominus y &= \text{rd}(x - y) = \text{rd}(43,9) = 4,4 \cdot 10^1, \\ x \otimes y &= \text{rd}(x \cdot y) = \text{rd}(49,5) \in \{ 4,9 \cdot 10^1, 5,0 \cdot 10^1 \}, \\ x \oslash y &= \text{rd}\left(\frac{x}{y}\right) = \text{rd}(40,9090\dots) = 4,1 \cdot 10^1. \end{aligned}$$

Bei IEEE-Rundung zur geraden Endziffer entsteht im Multiplikationsbeispiel 50.

Relativer Fehler einer Rechenoperation

Gemäß Annahme 4.12 gilt

$$x \odot y = \text{rd}(x \circ y).$$

Damit erhält man

$$\left| \frac{x \circ y - x \odot y}{x \circ y} \right| = \left| \frac{x \circ y - \text{rd}(x \circ y)}{x \circ y} \right|.$$

Falls

$$|x \circ y| \in \text{range}(F),$$

also das exakte Ergebnis im darstellbaren Bereich liegt, folgt aus der Definition der Maschinengenauigkeit:

$$\left| \frac{x \circ y - x \odot y}{x \circ y} \right| \leq \varepsilon(F).$$